

1. Research Overview

Introduction

سلام و وقت بخیر. موضوع پژوهش من «ارائه یک رویکرد مبتنی بر یادگیری فدرال برای تشخیص نفوذ در حملات لایه دوم شبکه همراه با هوش مصنوعی توضیح‌پذیر» است.

امروزه با گسترش شبکه‌های کامپیوتری، اینترنت اشیا و سرویس‌های آنلاین، حجم حملات سایبری نیز به شکل قابل توجهی افزایش یافته است. یکی از ابزارهای اصلی مقابله با این تهدیدات، سیستم‌های تشخیص نفوذ یا IDS هستند که وظیفه دارند ترافیک شبکه را پایش کرده و رفتارهای مشکوک را شناسایی کنند. با این حال، بیشتر سیستم‌های موجود بر حملات لایه‌های بالاتر شبکه تمرکز دارند و تهدیدات لایه دوم را کمتر مورد توجه قرار داده‌اند.

Problem Statement

حملات لایه دوم مانند ARP Spoofing، MAC Flooding و DHCP Starvation در داخل شبکه محلی رخ می‌دهند و معمولاً پیش از رسیدن ترافیک به فایروال یا سامانه‌های امنیتی اتفاق می‌افتند. از آنجا که این حملات اغلب ردپای مشخصی در سطح IP ایجاد نمی‌کنند، بسیاری از IDSهای سنتی قادر به شناسایی مؤثر آن‌ها نیستند. در نتیجه مهاجم می‌تواند مدت طولانی در شبکه باقی بماند، اطلاعات حساس را شنود کند یا حملات پیچیده‌تری را اجرا نماید.

Research Gap

مرور مطالعات اخیر نشان می‌دهد که پژوهش‌های متعددی در زمینه سیستم‌های تشخیص نفوذ مبتنی بر یادگیری فدرال و همچنین استفاده از روش‌های Explainable AI برای افزایش شفافیت مدل‌های یادگیری عمیق انجام شده است. با این حال، بخش عمده این تحقیقات بر تشخیص حملات عمومی شبکه، اینترنت اشیا یا ترافیک لایه‌های بالاتر متمرکز بوده‌اند.

در مقابل، حملات لایه دوم شبکه نظیر ARP Spoofing، MAC Flooding، DHCP Starvation و STP Manipulation کمتر در محیط‌های فدرال مورد مطالعه قرار گرفته‌اند. همچنین تأثیر توزیع ناهمگون داده‌ها (Non-IID) میان بخش‌های مختلف شبکه بر عملکرد سیستم‌های تشخیص نفوذ لایه دوم هنوز به طور کافی بررسی نشده است.

بنابراین خلأ اصلی این پژوهش، بررسی امکان پیاده‌سازی یک سیستم تشخیص نفوذ لایه دوم مبتنی بر یادگیری فدرال، ارزیابی عملکرد آن در شرایط Non-IID و تحلیل تصمیمات آن با استفاده از Explainable AI است.

Objectives, Questions and Hypotheses

هدف اصلی این پژوهش طراحی و ارزیابی یک سیستم تشخیص نفوذ لایه دوم مبتنی بر یادگیری فدرال است که بتواند ضمن حفظ حریم خصوصی داده‌ها، دقت تشخیص قابل قبولی ارائه داده و تصمیمات خود را به صورت قابل تفسیر در اختیار تحلیلگران امنیتی قرار دهد.

سؤالات اصلی پژوهش عبارت‌اند از:

- آیا یک سیستم تشخیص نفوذ فدرال می‌تواند عملکردی نزدیک به یک سیستم متمرکز داشته باشد؟
- توزیع ناهمگون داده‌ها (Non-IID) میان بخش‌های مختلف شبکه چه تأثیری بر عملکرد سیستم خواهد داشت؟
- آیا الگوریتم FedProx در شرایط Non-IID عملکرد بهتری نسبت به FedAvg ارائه می‌دهد؟
- آیا SHAP می‌تواند ویژگی‌های مؤثر در تشخیص حملات لایه دوم را به صورت معنادار شناسایی و تبیین کند؟
- آیا چارچوب پیشنهادی قابلیت اجرا روی سخت‌افزارهای سبک و محدود از نظر منابع مانند Raspberry Pi را دارد؟

فرضیه‌های پژوهش عبارت‌اند از:

- مدل فدرال پیشنهادی می‌تواند با اختلاف عملکرد کمتر از ۵ درصد نسبت به مدل متمرکز عمل کند.
- الگوریتم FedProx در شرایط داده‌های ناهمگون نسبت به FedAvg پایداری و دقت بیشتری ارائه خواهد داد.
- SHAP قادر خواهد بود مهم‌ترین ویژگی‌های مؤثر در تشخیص حملات لایه دوم را مشخص کند.
- سیستم پیشنهادی قابلیت استقرار روی تجهیزات سبک لبه شبکه را با سر بار محاسباتی قابل قبول خواهد داشت.

2. Literature and Research Background

Related Work

سیستم‌های تشخیص نفوذ از دیدگاه‌های مختلف طبقه‌بندی می‌شوند. از نظر محل استقرار، شامل HIDS و NIDS هستند. همچنین از نظر تکامل تاریخی، از سیستم‌های مبتنی بر امضا به سمت مدل‌های یادگیری ماشین و سپس یادگیری عمیق حرکت کرده‌اند.

در سال‌های اخیر، مدل‌های یادگیری عمیق به دلیل توانایی بالا در استخراج الگوهای پیچیده، نتایج بسیار موفق‌تری در تشخیص حملات شبکه ارائه کرده‌اند. یکی از مهم‌ترین مطالعات در این زمینه پژوهش Javeed و همکاران است که از معماری CNN و Bi-LSTM استفاده کرده و به دقت بیش از ۹۹ درصد روی مجموعه داده‌های CICIDS2017 و Edge-IIoT دست یافته است.

Research Gap Analysis

با وجود پیشرفت‌های قابل توجه، اکثر پژوهش‌ها روی حملات لایه‌های ۳ تا ۷ متمرکز بوده‌اند و حملات لایه دوم کمتر مورد توجه قرار گرفته‌اند. علاوه بر این، اغلب مطالعات از مجموعه داده‌های تکراری مانند UNSW-KDD، MAC و STP Root Bridge Attack، DHCP Starvation و NB15 استفاده کرده‌اند. حملاتی مانند Flooding که در محیط‌های واقعی سازمانی اهمیت زیادی دارند، هنوز به اندازه کافی بررسی نشده‌اند. همچنین بیشتر راهکارهای موجود به صورت متمرکز طراحی شده‌اند و موضوع حفظ حریم خصوصی داده‌ها و توضیح‌پذیری مدل را به طور همزمان پوشش نمی‌دهند.

3. Methodology

Proposed Architecture

معماری پیشنهادی از سه بخش اصلی تشکیل شده است. در بخش نخست، چندین گره فدرال در قسمت‌های مختلف شبکه قرار دارند که داده‌های محلی را پردازش می‌کنند. در بخش دوم، یک سرور مرکزی وظیفه تجمیع مدل‌های محلی را بر عهده دارد. در بخش سوم نیز ماژول Explainable AI قرار گرفته است که دلایل تصمیمات مدل را برای تحلیلگران امنیتی نمایش می‌دهد.

CNN-BiLSTM Model

هسته اصلی سیستم پیشنهادی یک مدل ترکیبی CNN و Bi-LSTM است.

شبکه CNN مسئول استخراج ویژگی‌های محلی از ترافیک شبکه است. این شبکه الگوهایی مانند افزایش ناگهانی ترافیک، تغییرات غیرعادی یا رفتارهای خاص بسته‌ها را شناسایی می‌کند. پس از آن، لایه Max Pooling ابعاد داده را کاهش داده و مهم‌ترین ویژگی‌ها را حفظ می‌کند.

در مرحله بعد، خروجی CNN به شبکه Bi-LSTM داده می‌شود. مزیت اصلی Bi-LSTM این است که داده‌های ترتیبی را هم از گذشته به آینده و هم از آینده به گذشته تحلیل می‌کند. در نتیجه مدل می‌تواند وابستگی‌های زمانی پیچیده را بهتر یاد بگیرد و الگوهای حمله را با دقت بیشتری تشخیص دهد.

ترکیب این دو معماری باعث می‌شود مدل هم ویژگی‌های محلی و هم روابط زمانی را به صورت همزمان تحلیل کند. در پژوهش CL2-IDS این مدل توانسته به دقت ۹۵/۲۸ درصد در تشخیص حملات لایه دوم دست یابد.

بعد از آموزش مدل در نود یا دیوایس (IoT, ...) فیچر اوان آموزش به یک سرور مرکزی ارسال میشه نه داده های خام.

Federated Learning (FedProx)

در روش‌های سنتی، تمام داده‌های خام باید به یک سرور مرکزی منتقل شوند که این موضوع مشکلاتی مانند نقض حریم خصوصی و هزینه ارتباطی بالا را به همراه دارد.

در یادگیری فدرال، داده‌ها در محل تولید باقی می‌مانند و تنها پارامترهای مدل میان گره‌ها و سرور مبادله می‌شوند. این رویکرد علاوه بر حفظ حریم خصوصی، مقیاس‌پذیری سیستم را نیز افزایش می‌دهد.

در این پژوهش از الگوریتم FedProx استفاده می‌شود، زیرا نسبت به FedAvg در شرایطی که داده‌ها بین گره‌ها توزیع غیر یکنواخت دارند، عملکرد پایدارتری ارائه می‌دهد.

Explainable AI (SHAP-SHapley Additive exPlanations)

یکی از مهم‌ترین چالش‌های مدل‌های یادگیری عمیق، ماهیت جعبه سیاه آن‌هاست. به همین دلیل از روش SHAP برای توضیح تصمیمات مدل استفاده می‌کنیم.

SHAP مشخص می‌کند هر ویژگی چه میزان در تصمیم نهایی مدل تأثیر داشته است. برای مثال اگر سیستم یک حمله ARP Spoofing را تشخیص دهد، SHAP می‌تواند نشان دهد که نرخ بسته‌های ARP، تغییرات آدرس MAC یا حجم پیام‌های Broadcast تا چه اندازه در این تصمیم مؤثر بوده‌اند. یا بهتره به عبارت دیگر بگیم که shap میاد امتیازدهی به عناصر مختلف میکند که همین باعث چرایی تشخیص حمله وجود دارد برای تحلیلگر امنیت.

فرض کن یک شرکت از یک سیستم IDS مبتنی بر هوش مصنوعی استفاده می‌کند. این سیستم ترافیک شبکه را بررسی می‌کند و تصمیم می‌گیرد که یک اتصال «عادی» است یا «حمله».

ورودی به مدل

یک اتصال شبکه با ویژگی‌های زیر وارد سیستم می‌شود:

مقدار ویژگی

2ثانیه Duration

25بار Failed Logins

5000 Packets/sec

TCP Protocol

تعداد زیاد ورودهای ناموفق (25 بار) (بیشترین تأثیر را در تصمیم داشته است .
نرخ بسیار بالای بسته‌ها (5000 packet/sec) نیز نقش مهمی داشته است .
آدرس IP فرستنده قبلاً به عنوان مشکوک شناخته شده است .
و درنهایت

این قابلیت باعث افزایش اعتماد تحلیلگران امنیتی به نتایج سیستم می‌شود.

Datasets

برای ارزیابی سیستم از سه مجموعه داده استفاده خواهد شد:

- CL2-IDS برای آموزش و ارزیابی حملات لایه دوم
- BCAST IDS برای اعتبارسنجی در محیط واقعی
- CICIDS-2017 برای مقایسه با سیستم‌های متداول تشخیص نفوذ

همچنین داده‌های CL2-IDS میان چند گره فدرال تقسیم می‌شوند تا شرایط واقعی شبکه‌های سازمانی شبیه‌سازی شود.

4. Data Analysis

Evaluation Metrics

برای ارزیابی عملکرد سیستم از معیارهای Accuracy، Precision، Recall-Score، ROC-AUC و PR-AUC استفاده می‌شود. همچنین نرخ هشدارهای اشتباه، مصرف پردازنده و میزان حافظه نیز اندازه‌گیری خواهند شد تا قابلیت استفاده عملی سیستم بررسی شود.

Expected Results

انتظار می‌رود مدل فدرال پیشنهادی با اختلاف کمتر از پنج درصد نسبت به مدل متمرکز عمل کند و در عین حال حریم خصوصی داده‌ها را حفظ نماید. همچنین پیش‌بینی می‌شود FedProx در شرایط Non-IID عملکرد بهتری نسبت به FedAvg داشته باشد و SHAP بتواند ویژگی‌های کلیدی حملات را به‌صورت شفاف نمایش دهد.

Research Innovation

نوآوری این پژوهش صرفاً در ترکیب یادگیری فدرال و Explainable AI نیست، بلکه در بررسی سیستماتیک تشخیص نفوذ لایه دوم در محیط‌های فدرال نهفته است.

مهم‌ترین نوآوری‌های پژوهش عبارت‌اند از:

طراحی و ارزیابی یک چارچوب تشخیص نفوذ لایه دوم مبتنی بر یادگیری فدرال برای محیط‌های شبکه‌ای توزیع‌شده. بررسی اثر توزیع ناهمگون داده‌ها (Non-IID) بر عملکرد سیستم تشخیص نفوذ و تحلیل رفتار الگوریتم FedProx در این شرایط. استفاده از SHAP برای شناسایی و تحلیل ویژگی‌های مؤثر در تشخیص حملات لایه دوم و افزایش شفافیت تصمیمات مدل. ارزیابی عملی قابلیت استقرار سیستم روی تجهیزات سبک لبه شبکه مانند Raspberry Pi و تحلیل سربار محاسباتی آن.

5. Conclusions and Suggestions

Conclusion

در این پژوهش یک چارچوب جدید برای تشخیص نفوذ در شبکه‌های توزیع‌شده ارائه شد که سه فناوری یادگیری فدرال، یادگیری عمیق و هوش مصنوعی توضیح‌پذیر را در کنار یکدیگر به کار می‌گیرد.

هدف این سیستم شناسایی حملات لایه دوم، حفظ حریم خصوصی داده‌ها، کاهش هزینه‌های ارتباطی و افزایش شفافیت تصمیمات امنیتی است. انتظار می‌رود نتایج این پژوهش بتواند گامی مؤثر در توسعه نسل آینده سیستم‌های تشخیص نفوذ هوشمند باشد.

Future Work

در آینده می‌توان این چارچوب را برای سایر لایه‌های شبکه نیز توسعه داد، از الگوریتم‌های پیشرفته‌تر فدرال استفاده کرد و آن را در محیط‌های واقعی مبتنی بر اینترنت اشیا، شبکه‌های صنعتی و رایانش لبه مورد ارزیابی قرار داد.

6. Questions and Discussion

از توجه شما سپاسگزارم.

در این بخش آماده پاسخگویی به سؤالات و دریافت نظرات و پیشنهادهای شما هستم.